

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ  
УЧРЕЖДЕНИЕ ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ  
Национальный исследовательский университет  
«Высшая школа Экономики»

ФАКУЛЬТЕТ ЭКОНОМИЧЕСКИХ НАУК

ОБРАЗОВАТЕЛЬНАЯ ПРОГРАММА «ЭКОНОМИКА»

---

## КУРСОВАЯ РАБОТА

Стохастические методы оптимизации

---

Выполнил:  
студент группы БЭК1812  
Хайкин ГЛЕБ АЛЕКСЕЕВИЧ

Научный руководитель:  
старший преподаватель  
Борзых Дмитрий Александрович



МОСКВА — 2020

# Оглавление

<b>1. Введение</b>	3
<b>2. Методы и их применение</b>	4
2.1. Имитация отжига	4
2.1.1. Алгоритм	4
2.1.2. N ферзей	5
2.1.3. Минимизация негладкой функции	10
2.1.4. Задача коммивояжера	12
2.1.5. Вывод	14
<b>Заключение</b>	16
<b>Список литературы</b>	17

# 1. Введение

jjj.

## 2. Методы и их применение

### 2.1. Имитация отжига

*Имитация отжига* (simulated annealing) представляет собой алгоритм решения задачи поиску глобального оптимума некоторой функции  $F : \mathbb{X} \rightarrow \mathbb{R}$  через упорядоченный стохастический поиск, базирующийся на моделировании физического процесса кристаллизации вещества из жидкого состояния в твердое.

Для описания метода рассмотрим задачу нахождения глобального минимума:

$$F(x) \rightarrow \min_{x \in \mathbb{X}},$$

где  $x = (x_1, \dots, x_m)$  — вектор всех состояний,  $\mathbb{X}$  — множество всех состояний.

#### 2.1.1. Алгоритм

Положим, что  $k = 0$  и изначально температура зафиксированна на определенном уровне  $T(k) = \text{const.}$

1. Из множества всех состояний выберем случайный элемент  $\hat{x}(k) \equiv x_i$ ,  
 $i \in (1, \dots, m).$
2. Понизим температуру одним из следующих способов:

а) Больцмановский отжиг

$$T(k) = \frac{T(0)}{\ln(1 + k)}, \quad k > 0 \quad (2.1)$$

б) Отжиг Коши

$$T(k) = \frac{T(0)}{k} \quad (2.2)$$

в) Метод тушения

$$T(k + 1) = \alpha T(k), \quad \alpha \in (0, 1) \quad (2.3)$$

3. Пусть следующий элемент зависит от функции из семейства симметричных вероятностных распределений  $G : \mathbb{X} \rightarrow \mathbb{X}$ , порождающей новое состояние:

$$\tilde{x}(k) \sim G(\hat{x}(k), T(k)).$$

а) Часто  $G$  выбирается из семейства нормальных распределений:

$$G(\tilde{x}; \hat{x}, T) = \frac{1}{\sqrt{(2\pi)^D T}} \exp \left\{ \frac{-|\tilde{x} - \hat{x}|^2}{2T} \right\}, \quad (2.4)$$

где  $\hat{x}$  — математическое ожидание,  $T$  — дисперсия,  $D$  — размерность пространства всех состояний.

б) Также для  $D = 1$  используется распределение Коши с плотностью:

$$G(\tilde{x}; \hat{x}, T) = \frac{1}{\pi} \frac{T}{|\tilde{x} - \hat{x}|^2 + T^2}, \quad (2.5)$$

где  $\hat{x}$  — параметр сдвига,  $T$  — параметр масштаба.

4. Рассчитываем разницу двух функций:

$$\Delta F = F(\tilde{x}(k)) - F(\hat{x}(k)).$$

5. Принимаем  $\tilde{x}(k)$  за новый элемент, то есть  $\hat{x}(k+1) \equiv \tilde{x}(k)$ , с вероятностью

$$\mathbb{P}(\{\hat{x}(k+1) = \tilde{x}(k)\}) = \begin{cases} 1, & \Delta F < 0 \\ \exp\left\{-\frac{\Delta F}{T(k)}\right\}, & \Delta F \geq 0 \end{cases} \quad (2.6)$$

и отвергаем его, то есть  $\hat{x}(k+1) \equiv \hat{x}(k)$ , с вероятностью

$$q = 1 - \mathbb{P}(\{\hat{x}(k+1) = \tilde{x}(k)\}).$$

Заметим, чем выше температура, тем больше вероятность принять состояние хуже текущего ( $\Delta F \geq 0$ ).

6. Возвращаемся к пункту 2, пока не достигнем глобального минимума.

## 2.1.2. $N$ ферзей

Рассмотрим задачу, в которой необходимо расставить  $N$  ферзей на шахматной доске размера  $N \times N$  так, чтобы ни один из них не «бил» другого.

В таком случае, множество всех состояний  $\mathbb{X}$  будет содержать всевозможные расстановки ферзей на шахматной доске. Общее число возможных расположений  $n$  ферзей на  $N \times N$ -клеточной доске равно:

$$\binom{N \times N}{n} = \frac{N \times N!}{n!(N \times N - n)!}$$

Тогда функция  $F : \mathbb{X} \rightarrow \mathbb{R}$  будет выдавать количество атак ферзей, и решением данной задачи будет нахождение такого расположения  $x^*$ , что  $F(x^*) \equiv 0$ .

Зафиксируем изначальное расположение ферзей на шахматной доске. Очевидно, что несколько ферзей не могут находиться на одной вертикали или горизонтали, ибо тогда они будут находиться под ударом друг-друга. Следовательно, наша задача сужается к поиску расположения:

$$x^* = (q_1, \dots, q_n) = \{(1, h_1), \dots, (n, h_n) : h_i \in (1, \dots, n), h_1 \neq \dots \neq h_n\}, \quad (2.7)$$

где  $(i, h_i)$  — расположение  $i$ -го ферзя ( $q_i$ ) на  $i$ -ой вертикали по горизонтали  $h_i$ .

Отметим, что такая задача имеет  $N!$  решений.

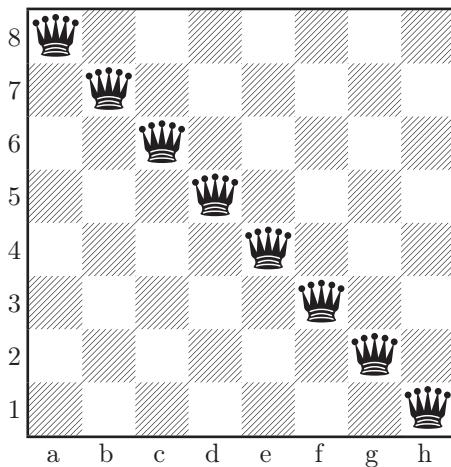


Рисунок 2.1 — Изначальное расположение.

Определим функцию, которая будет создавать изначальное неоптимальное расположение, в общем виде. Учтем, что несколько ферзей не могут находиться на одной вертикали или горизонтали.

```
In: def queens(N):
    ver = np.arange(1, N + 1)
    hor = np.arange(1, N + 1)
    np.random.shuffle(hor)
    return np.column_stack((ver, hor)) # получаем массив
# размерности (N, 2), отображающий расположение ферзей
```

Выведем первоначальное расположение ферзей для стандартной доски  $8 \times 8$ , где первый столбец массива — расположение по вертикали, второй столбец массива — расположение по горизонтали. Для наглядности — презентации оптимизационного процесса — выстроим изначальную расстановку на главной диагонали (рис. 2.1).

```
In:    matrix = queens(8)
      matrix
```

```
Out:   array([[1, 1],
           [2, 2],
           [3, 3],
           [4, 4],
           [5, 5],
           [6, 6],
           [7, 7],
           [8, 8]])
```

Функция F, которая выявляет количество атак ферзей, выглядит следующим образом:

```
In:    def F(Q, N):
      cnt = 0
      for i in range(N):
          for j in range(i + 1, N):
              if abs(Q[i, 0] - Q[j, 0]) == abs(Q[i, 1] - Q[j, 1]):
                  cnt += 1
      return cnt * 2 # учитываем взаимные атаки
```

Посмотрим, сколько у атак у исходной расстановки.

```
In:    F(matrix, 8)
```

```
Out:   56
```

В нашей задачи функция G будет случайной незначительной перестановкой номеров горизонтали в исходном наборе.

```
In:    def G(Q, N):
      pos = Q.copy()
      while True:
          i = np.random.randint(0, N - 1)
          j = np.random.randint(0, N - 1)
          if i != j:
              break
      pos[i, 1], pos[j, 1] = pos[j, 1], pos[i, 1]
      return pos # получаем новое расположение
```

Теперь выведем и сам метод имитации отжига.

```
In:    def SA(Q, T, schedule):
      N = np.shape(Q)[0]
      x_hat = Q.copy()
      while F(x_hat, N) != 0:
          x_tilda = G(x_hat, N)
          delta = F(x_tilda, N) - F(x_hat, N)
          prob = np.exp(- delta / T)
```

```

if (delta < 0) or (prob >= np.random.random()):
    x_hat = x_tilda
T *= schedule # используем метод тушения для понижения температуры
return x_hat

```

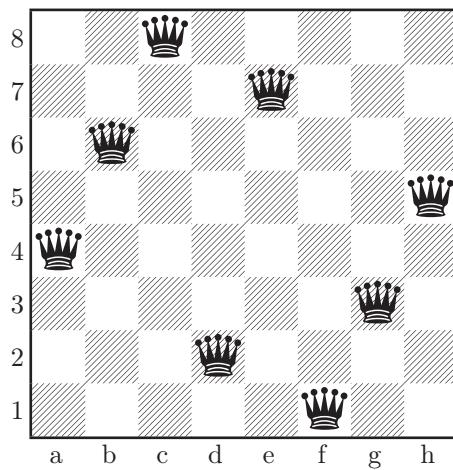


Рисунок 2.2 — Оптимальное расположение

Так для нашего примера с гиперпараметрами  $T(0) = 100$ ,  $\alpha = 0.9$  мы получаем следующее оптимальное решение (рис. 2.2):

In: `SA(matrix, 100, 0.9)`

Out: `array([[1, 5],
 [2, 3],
 [3, 1],
 [4, 7],
 [5, 2],
 [6, 8],
 [7, 6],
 [8, 4]])`

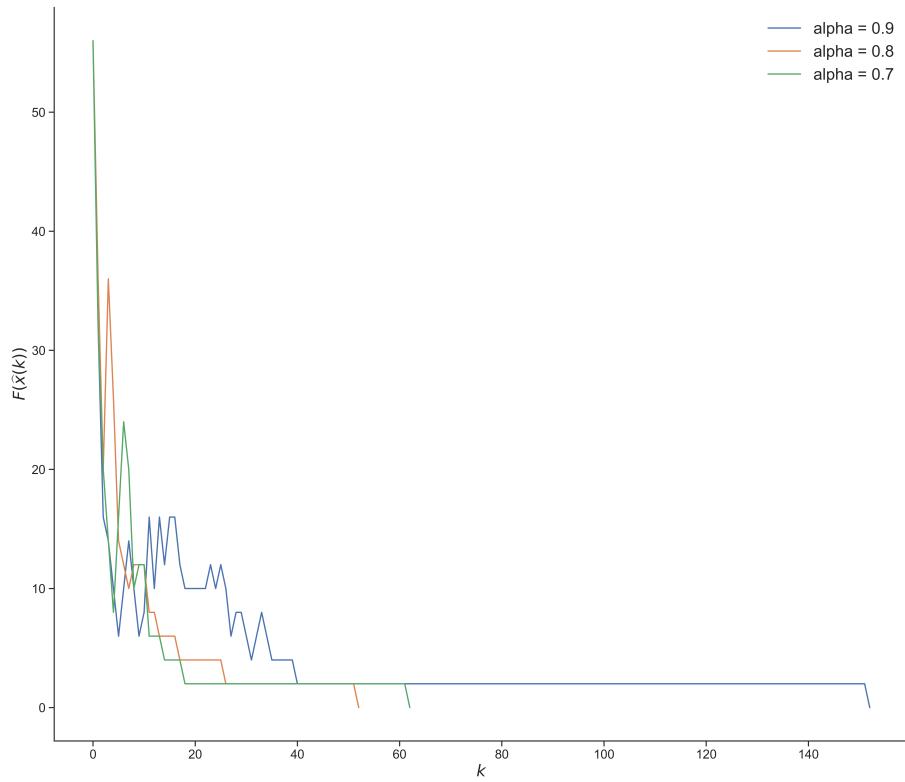


Рисунок 2.3 — Оптимизация расстановки 8 ферзей в зависимости от гиперпараметра  $\alpha$ .

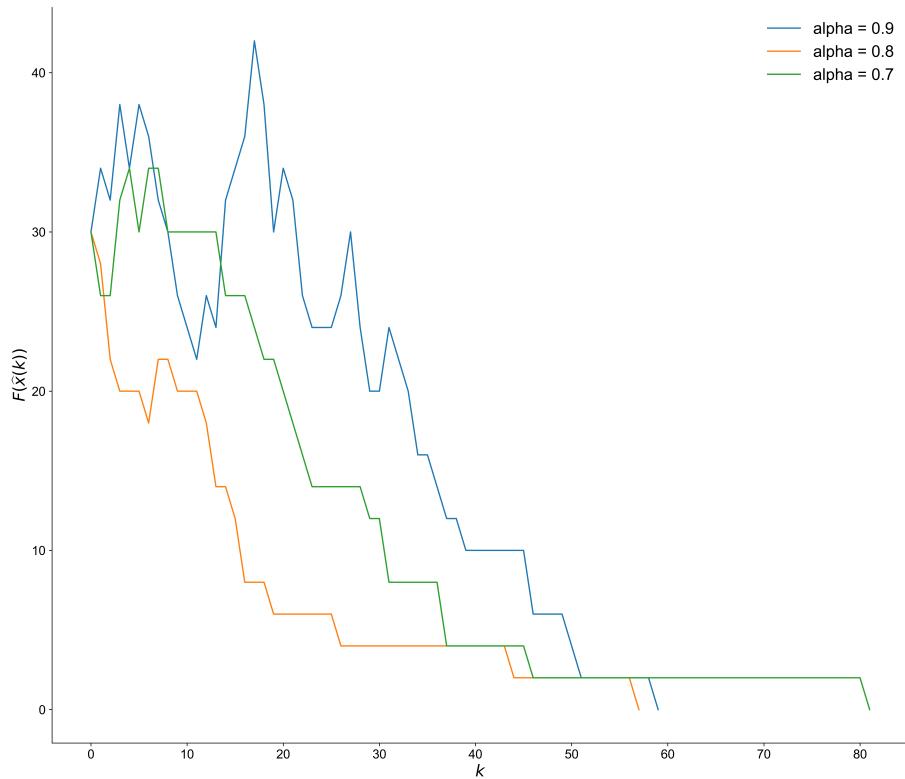


Рисунок 2.4 — Оптимизация расстановки 25 ферзей в зависимости от гиперпараметра  $\alpha$ .

### 2.1.3. Минимизация негладкой функции

Воспользуемся алгоритмом имитации отжига для нахождения глобального минимума следующей функции:

$$f(x) = x^2(1 + |\sin 80x|).$$

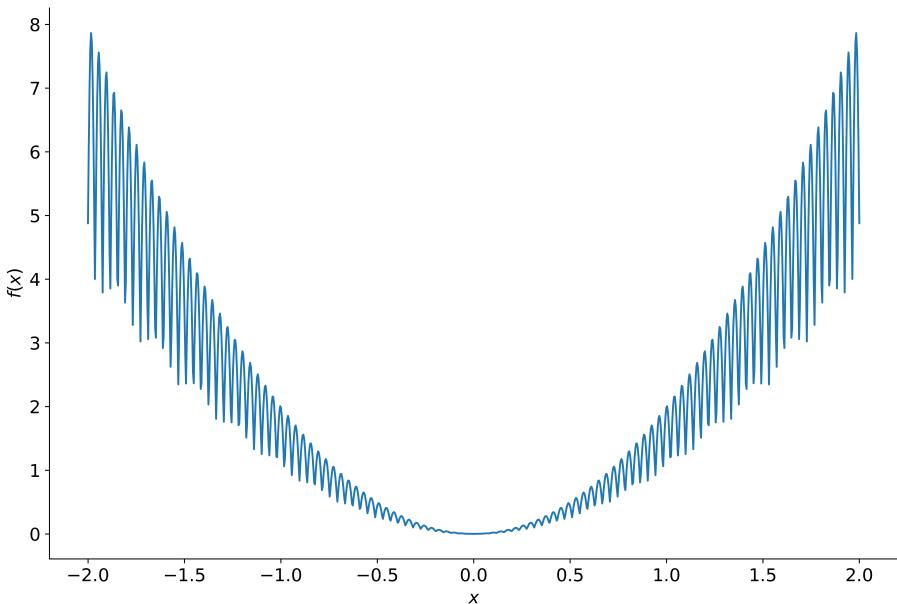


Рисунок 2.5

Стандартные методы оптимизации — к примеру, метод градиентного спуска — в данном случае не применимы. Вследствие наличия модуля эта функция не дифференцируема. Также она имеет очень большое количество локальных минимумов, что затрудняет, к примеру, мультистарт — запуск градиентного спуска из разных начальных направлений.

Применим наш алгоритм к данной задаче. Пусть  $T(0) = 0.6$ . Для понижения температуры будем использовать Больцмановский отжиг (2.1), а в качестве функции вероятностных распределений  $G$  — семейство нормальных распределений (2.4).

```
In: def SA(space, T, epsilon): # за space берется np.linspace(-2, 2, 1000)
    x_hat = np.random.choice(space)
    T_0 = T
    k = 1
    while True:
        x_tilda = np.random.normal(x_hat, T)
        delta = F(x_tilda) - F(x_hat)
        prob = np.exp(-delta / T)
        if (delta < 0) or (prob >= np.random.random()):
            x_hat = x_tilda
```

```

if (x_hat < epsilon) and (x_hat > 0):
    return x_hat
T = T_0 / np.log(1 + k)
k += 1

```

Остановка итерационного процесса и скорость метода зависят от того, насколько близко мы хотим приблизиться к глобальному минимуму. Так, при точности  $10^{-1}$ , что довольно много, для 1000 повторений алгоритма метод отжига находит глобальный минимум в среднем за 1.97e-3 секунды со стандартным отклонением в 3.47e-5 секунды. Однако, увеличив точность до  $10^{-6}$ , среднюю скорость занимает уже 1.27 секунды со стандартным отклонением в 2.1e-5 секунды. Это наглядно представлено на рисунке 2.6.

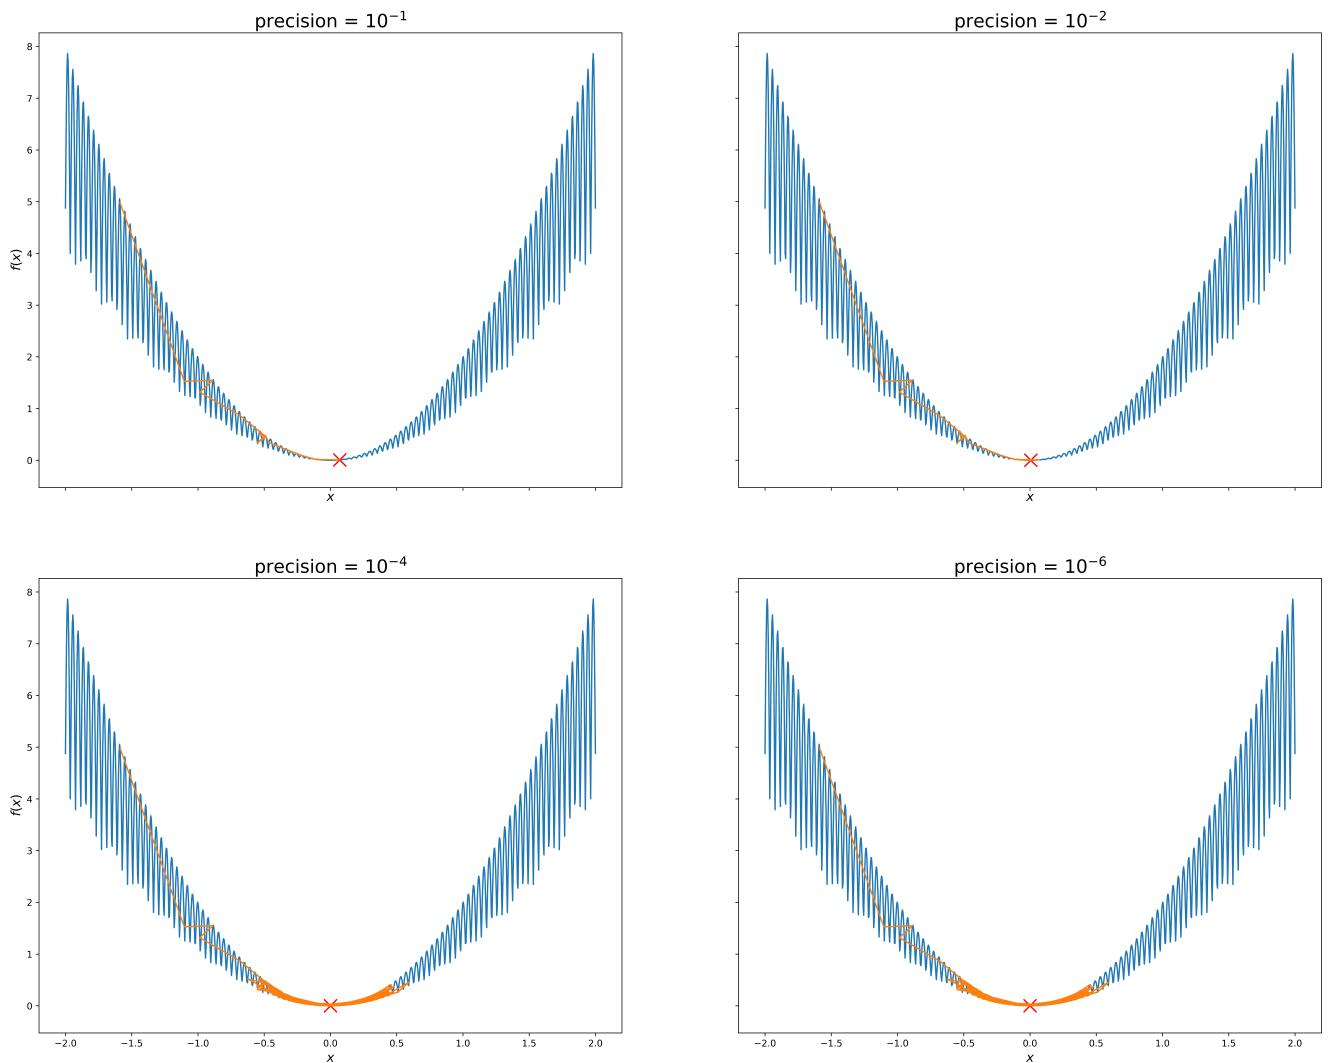


Рисунок 2.6 — Оптимизационный процесс в зависимости от точности.

## 2.1.4. Задача коммивояжера

Задача коммивояжера или TSP (Traveling Salesman Problem) является образцовым методом проверки многих оптимизационных алгоритмов и заключается в поиске кратчайшего маршрута между городами. Путь должен быть проложен так, чтобы маршрут единственно проходил через все города и его конечная точка совпадала с изначальной.

TSP имеет множество приложений в планировании и логистике, а также выступает в качестве подзадачи во многих других областях. В данных приложениях города могут представлять, к примеру, клиентов, а расстояние между городами — время или стоимость путешествия.

В нашем решении создадим карту из 26 городов.

```
In: def map_city(cities_num):
    letters = [chr(i) for i in range(65, 65 + cities_num)]
    x = np.random.randint(1, 500, size= (cities_num, 2))
    return letters, x

In: names, cities = map_city(26)
store_val = list(zip(names, cities))
```

Определим расстояние от города  $i$  до всех остальных через словарь. Для измерения расстояния между городами будем использовать евклидову метрику. Напомним, что евклидово расстояние между точками  $x = (x_1, \dots, x_d)$  и  $u = (u_1, \dots, u_d)$  задается как:

$$\rho(x, u) = \sqrt{\sum_{i=1}^d (x_i - u_i)^2}$$

```
In: def distance_dict(cities, n):
    d = dict()
    for i in range(n):
        city = dict()
        for j in range(n):
            if i == j:
                continue
            c_a = cities[i][1]
            c_b = cities[j][1]
            dist = np.sqrt((c_a[0] - c_b[0]) ** 2 + (c_a[1] - c_b[1]) ** 2)
            city[cities[j][0]] = dist
        d[cities[i][0]] = city
    return d
```

```
In: cities_d = distance_dict(store_val, len(store_val))
```

Тогда изначальный маршрут будет выглядеть следующим образом:

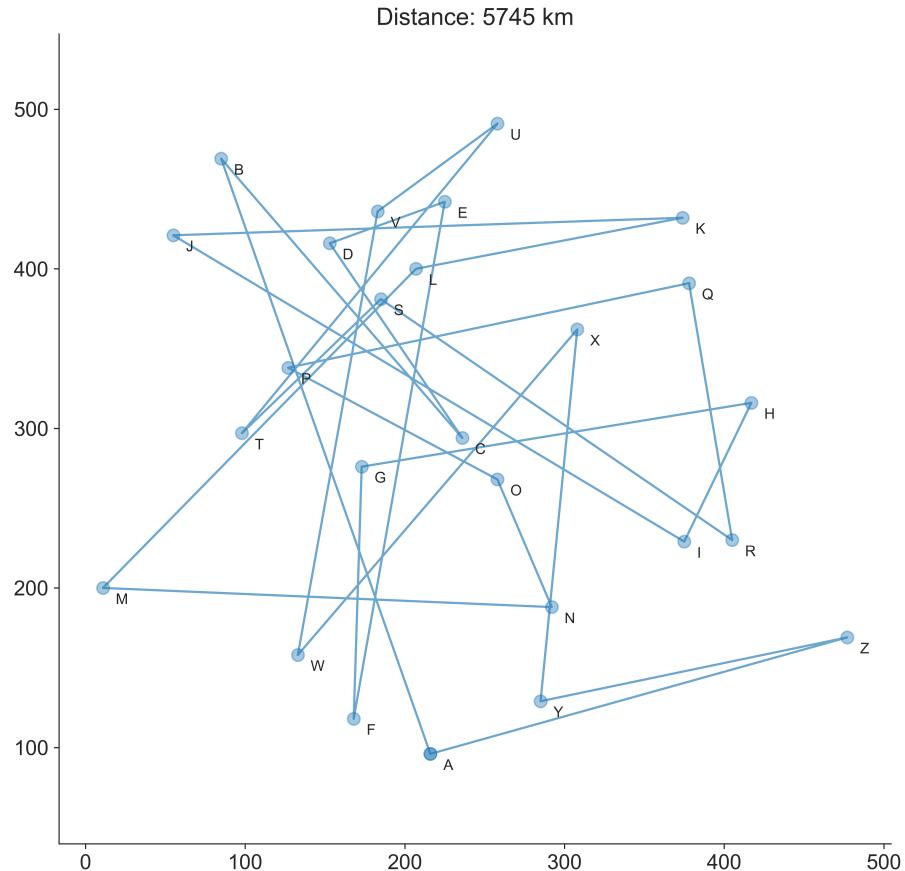


Рисунок 2.7

Функция для подсчета общего расстояния путешествия:

```
In: def F(path, cities):
    dist = 0
    for i in range(len(path) - 1):
        dist += cities[path[i]][path[i + 1]]
    dist += cities[path[i + 1]][path[0]]
    return dist
```

За функцию G будет выступать простая перестановка как и в задаче о N ферзях.

```
In: def G(path, n):
    pos = path.copy()
    while True:
        i = np.random.randint(0, n - 1)
        j = np.random.randint(0, n - 1)
        if i != j:
            break
    pos[i], pos[j] = pos[j], pos[i]
```

```
    return pos
```

Метод отжига:

```
In: def SA(path, T):
    path_hat = path
    n = len(path_hat)
    np.random.shuffle(path_hat)
    T_0 = T
    k = 1
    for i in range(100000):
        path_tilda = G(path_hat, n)
        delta = F(path_tilda, cities_d) - F(path_hat, cities_d)
        prob = np.exp(-delta / T)
        if (delta < 0) or (prob >= np.random.random()):
            path_hat = path_tilda
        T = T_0 / np.log(k + 1)
        k += 1
    return path_hat
```

Построим оптимальный маршрут.

```
In: path_opt = SA(names, 100)
```

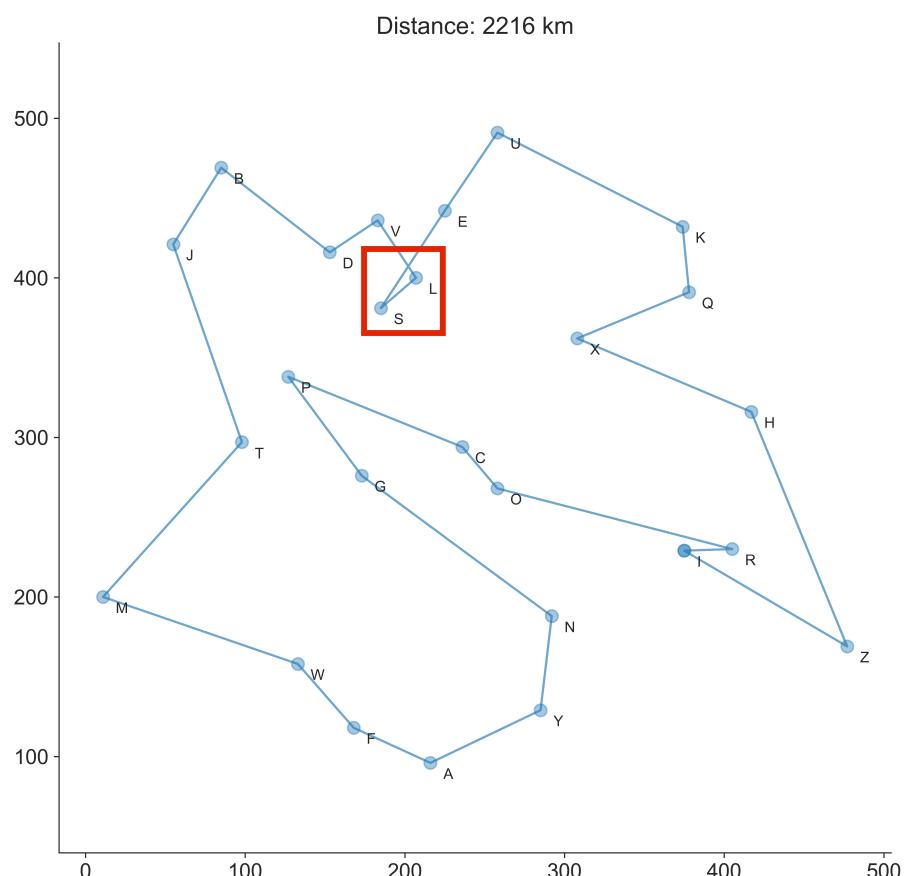


Рисунок 2.8

## 2.1.5. Вывод

# Заключение

Основные результаты работы заключаются в следующем.

1. На основе анализа ...
2. Численные исследования показали, что ...
3. Математическое моделирование показало ...
4. Для выполнения поставленных задач был создан ...

И какая-нибудь заключающая фраза.

Последний параграф может включать благодарности. В заключение автор выражает благодарность и большую признательность научному руководителю Иванову И. И. за поддержку, помошь, обсуждение результатов и научное руководство. Также автор благодарит Сидорова А. А. и Петрова Б. Б. за помошь в работе с образцами, Рабиновича В. В. за предоставленные образцы и обсуждение результатов, Занудягину Г. Г. и авторов шаблона \*Russian-Phd-LaTeX-Dissertation-Template\* за помошь в оформлении диссертации. Автор также благодарит много разных людей и всех, кто сделал настоящую работу автора возможной.

## Список литературы

- [1] Шамин Р.В. (2019) Практическое руководство по машинному обучению. — М.: Научный канал. — 93 с.